

【晓黎（杭州）人工智能科技有限公司】落实算法安全主体责任基本情况

算法安全专职机构

晓黎（杭州）人工智能科技有限公司为自然人独资的有限责任公司，规模小、决策链短。为落实算法安全主体责任，公司设立「算法安全工作组」作为算法安全专职机构，对公司算法安全工作负总体责任。

组成：组长由法定代表人、总经理邓湘雷担任，同时兼任算法安全责任人；下设四个职能岗——算法安全评估岗、内容安全岗、数据与个人信息保护岗、应急处置岗。现阶段四个岗位均由邓湘雷担任。公司在制度中明确：人员规模扩大后必须按岗配人并书面任命，不得由一人长期兼任全部岗位。

职责分工：组长审定算法安全制度，决定算法的上线、变更与下线，组织安全自评估，对监管问询负总责；算法安全评估岗组织上线前评估与年度自评估并维护风险清单；内容安全岗审核输入输出安全策略并处置违法和不良信息；数据与个人信息保护岗管理数据出境闸门与授权记录、维护个人信息处理规则；应急处置岗值守安全事件、执行应急预案并对接监管部门。

责任范围：本机构对算法安全事项具有否决权，独立于产品研发。任何涉及算法的功能上线，必须经本机构书面确认；未经确认不得发布。

算法安全管理制度建设

公司依据《互联网信息服务算法推荐管理规定》《互联网信息服务深度合成管理规定》《生成式人工智能服务管理暂行办法》《个人信息保护法》《数据安全法》《网络安全法》，制定《算法安全管理办法》及其配套细则。制度体系包含：算法安全管理办法（总纲）、算法安全自评估制度、算法安全监测制度、算法安全事件应急处置制度、算法违法违规处置制度、算法备案与变更管理制度、用户权益保护与投诉处理制度、数据出境与授权管理制度。

上述制度是约束公司自身行为、规范算法研发和管理工作流程的依据。算法需求评审、开发、测试、上线、变更、下线各环节均须留存书面记录，记录保存不少于三年。

（一）算法安全自评估制度建设

建立三类自评估：算法上线前自评估、年度定期自评估、重大变更即时自评估。算法机制机理、数据来源与合法性、输出内容安全性、用户权益影响、标识落实情况、风险与防控措施，均为必评内容。

评估流程：算法安全评估岗起草，组长审定，形成《算法安全自评估报告》留档；属于备案范围的，按备案要求提交。评估结论为不通过时，算法不得上线；已上线的应立即下线整改。

现阶段状态：本算法尚未公开提供服务。公司目前仍处于开发阶段，尚未对外开展服务，尚无公开用户，亦无真实

服务量可供统计。备案用的算法安全自评估报告已完成编制，并已按备案要求准备相关材料。

（二）算法安全监测制度建设

公司建立覆盖信息安全、数据安全、用户个人信息安全、算法安全四个方面的长效监测制度，明确监测指标、监测频次、责任岗位与处置流程。算法上线后实时监测，每周汇总复核一次。

信息安全监测

对输入与输出实施双向内容安全审查，建立违法和不良信息特征库，命中即阻断本次请求并记录；信息源方面，算法仅使用用户主动输入和用户自有数据，不引入未获授权的第三方语料。

数据安全监测

数据分级：用户任务内容属于用户敏感数据，采用本地加密存储，服务端不解密。出境管控：任何数据离开设备前，必须按“功能 + 目的地”逐项取得用户授权；用户变更目的地时，系统自动删除不再匹配的历史授权，避免一次授权被扩大使用。传输全程加密。研发过程管理：实行代码审查与依赖引入审查，本产品不引入任何第三方 AI 厂商 SDK；变更留痕可追溯。

用户个人信息安全监测

最小必要：算法处理只使用完成该项功能所必需的数据，不采集与服务无关的个人信息。用户权利：提供个人信息查询、更正、删除、撤回同意与账号注销通道。授权可撤

回：用户关闭开关即停止数据出境，并同步清理相应的授权记录。加密保护：本地优先并采用端到端加密，服务端无法读取用户任务内容。

算法安全监测

算法漏洞监测：持续跟踪上游模型与依赖组件的安全公告，建立补丁评估与升级流程，发现高危漏洞时先停用相关能力再评估修复。

算法被恶意利用监测：识别高频、异常与越权调用并予限制；本产品的本机接口默认关闭，仅监听回环地址，且每个工具能力需用户逐项授权后方可使用。

输出可控性：算法仅产出建议，类型上无法直接产生任何数据写入或删除操作，必须经用户确认后才生效。

可用性熔断：上游服务异常时按健康状态降级或停用，不静默降级为不安全的处理路径。

（三）算法安全事件应急处理制度建设

事件分级：一般事件为局部功能异常；较大事件为输出违法和不良信息或发生数据越权；重大事件为大规模数据泄露、服务中断或被监管部门通报。

处置步骤：发现与上报 → 先行阻断（停用相关功能或停止数据出境）→ 影响面评估 → 修复 → 验证 → 恢复服务 → 复盘并形成报告 → 按要求向监管部门报告。

责任人与时限：应急处置岗第一时间处置，组长负责对外报告与决策。重大事件一小时内启动处置，二十四小时内形成初步报告，并按监管要求报送。

现阶段状态：本算法尚未公开提供服务，无公开用户，应急预案处于待启用状态，演练脚本已编制完成。

（四）算法违法违规处置制度建设

数据使用违规（超范围采集、未获授权出境、超出期限保留）：立即停止相应处理行为，删除相关数据，并追究责任岗位责任。

信息安全违规（未拦截违法和不良信息、未按规定标识）：立即下线相关功能，完成整改并通过重新评估后方可恢复。

用户权益保护违规（未提供删除或撤回通道、以不当方式诱导授权）：限期整改，未完成整改不得上线。

算法安全违规（设计存在缺陷、开发引入风险、测试覆盖不足、未评估即上线、上线后未持续监测）：阻断上线或立即下线，并按环节追究责任。

处罚措施：对责任岗位给予书面警告、暂停其算法相关操作权限；情节严重的解除劳动关系；涉嫌违法犯罪的移送司法机关。所有处置过程与结论留档不少于三年。

（五）其他制度

算法备案与变更管理制度：算法上线、发生重大变更、终止服务时，按法定时限办理备案、变更或注销手续。

用户权益保护与投诉处理制度：设立面向公众的投诉受理渠道，明确受理范围、处理时限与反馈方式，对用户关于算法结果的异议予以受理和答复。

数据出境与授权管理制度：坚持逐“功能 + 目的地”授权、可撤回、可审计；未经授权数据不出设备。

安全培训制度：算法安全责任人每年参加不少于一次算法安全与个人信息保护培训，并留存记录。

现阶段重要说明：本产品的“托管 AI”（即经本公司云端调用上游模型的模式）的数据保留策略尚未定案。代码层已设置硬性闸门，在该策略定案并通过合规评估之前，该模式无法被启用。在此之前，本公司不对外提供托管 AI 服务。自备端点模式的数据不经过本公司服务器。

附件

本文件即为上述各项制度的集中表述。制度清单及编制状态如下：

- 算法安全管理办法（总纲） —— 已定稿（本文件）
- 算法安全自评估制度 —— 已定稿（见本文件第一部分）
- 算法安全监测制度 —— 已定稿（见本文件第二部分）
- 算法安全事件应急处置制度 —— 已定稿（见本文件第三部分）
- 算法违法违规处置制度 —— 已定稿（见本文件第四部分）
- 算法备案与变更管理制度 —— 已定稿（见本文件第五部分）
- 用户权益保护与投诉处理制度 —— 编制中，随服务

上线同步发布

· 数据出境与授权管理制度 —— 编制中，随服务上线
同步发布

· 算法安全工作组任命书 —— 随本文件盖章后生效